# Automating Bacterial Colony Segmentation with Deep Learning

Bachelor’s Thesis by Leonhard Driesch,
University of Münster – Computer Science Department

# Kontext

- Petri-Schalen werden verwendet, um Vorkommnisse von Mikroorganismen festzustellen
- Prozess: Probe auf Petri-Schale mit nährreichem Boden auftragen, einige Tage warten, Kolonien zählen
- Gezählte Kolonien lassen auf Vorkommnisse in der Probe zurückschließen

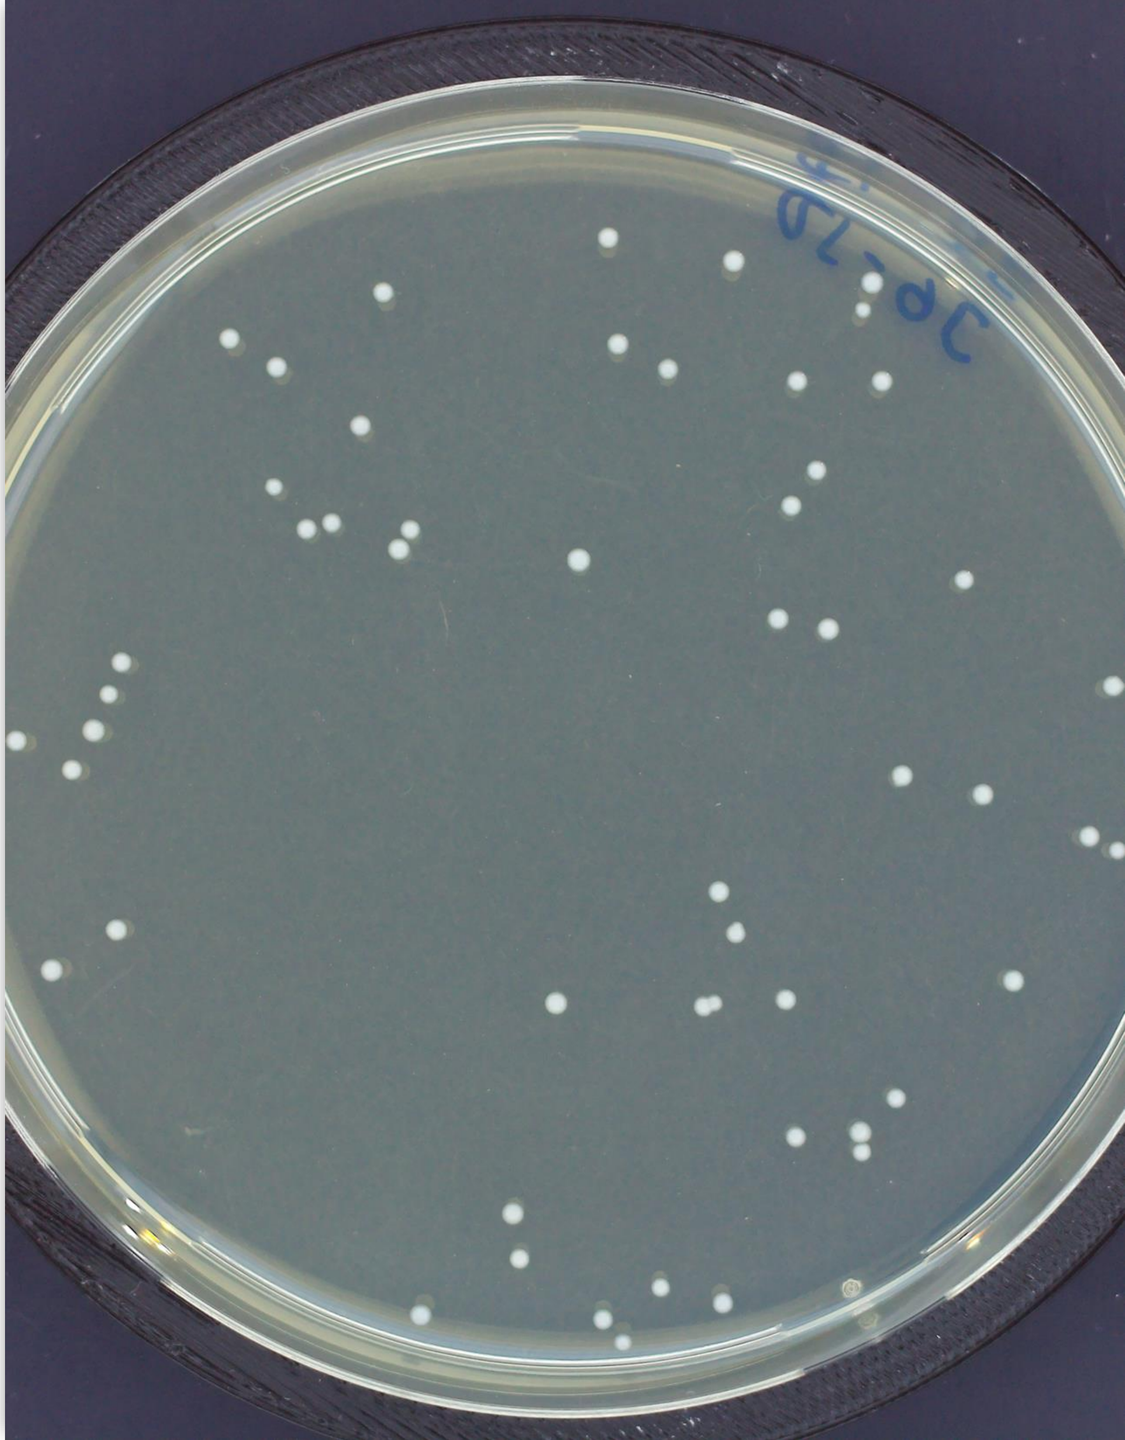

# Problem

- Manuelles Zählen der Kolonien dauert lange
- Bis zu 3000 Kolonien

stuart
18
colony counter | SC6+

# Ziel der Bachelorarbeit

- Automatisierung / Unterstützung des Zählprozesses durch Computer Vision
- Kolonien lokalisieren + Zählen

# Dataset

# Photos sammeln

- Photobox der Bachelorarbeit von Emile
- Bildauflösung 3040x3040px
- Konstante Schärfe- & Lichtverhältnisse

-> 529 Fotos

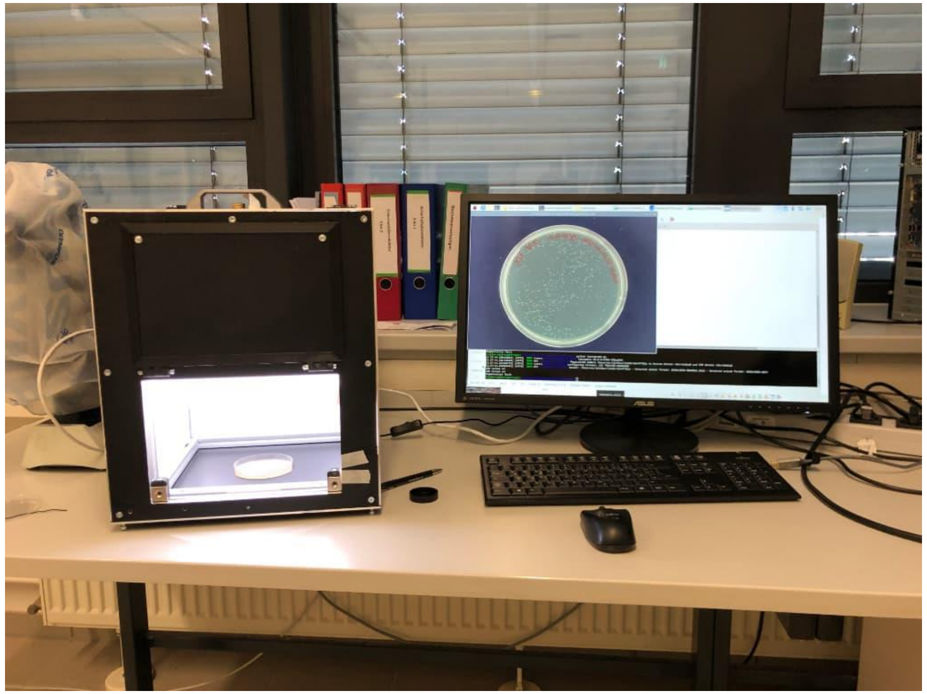

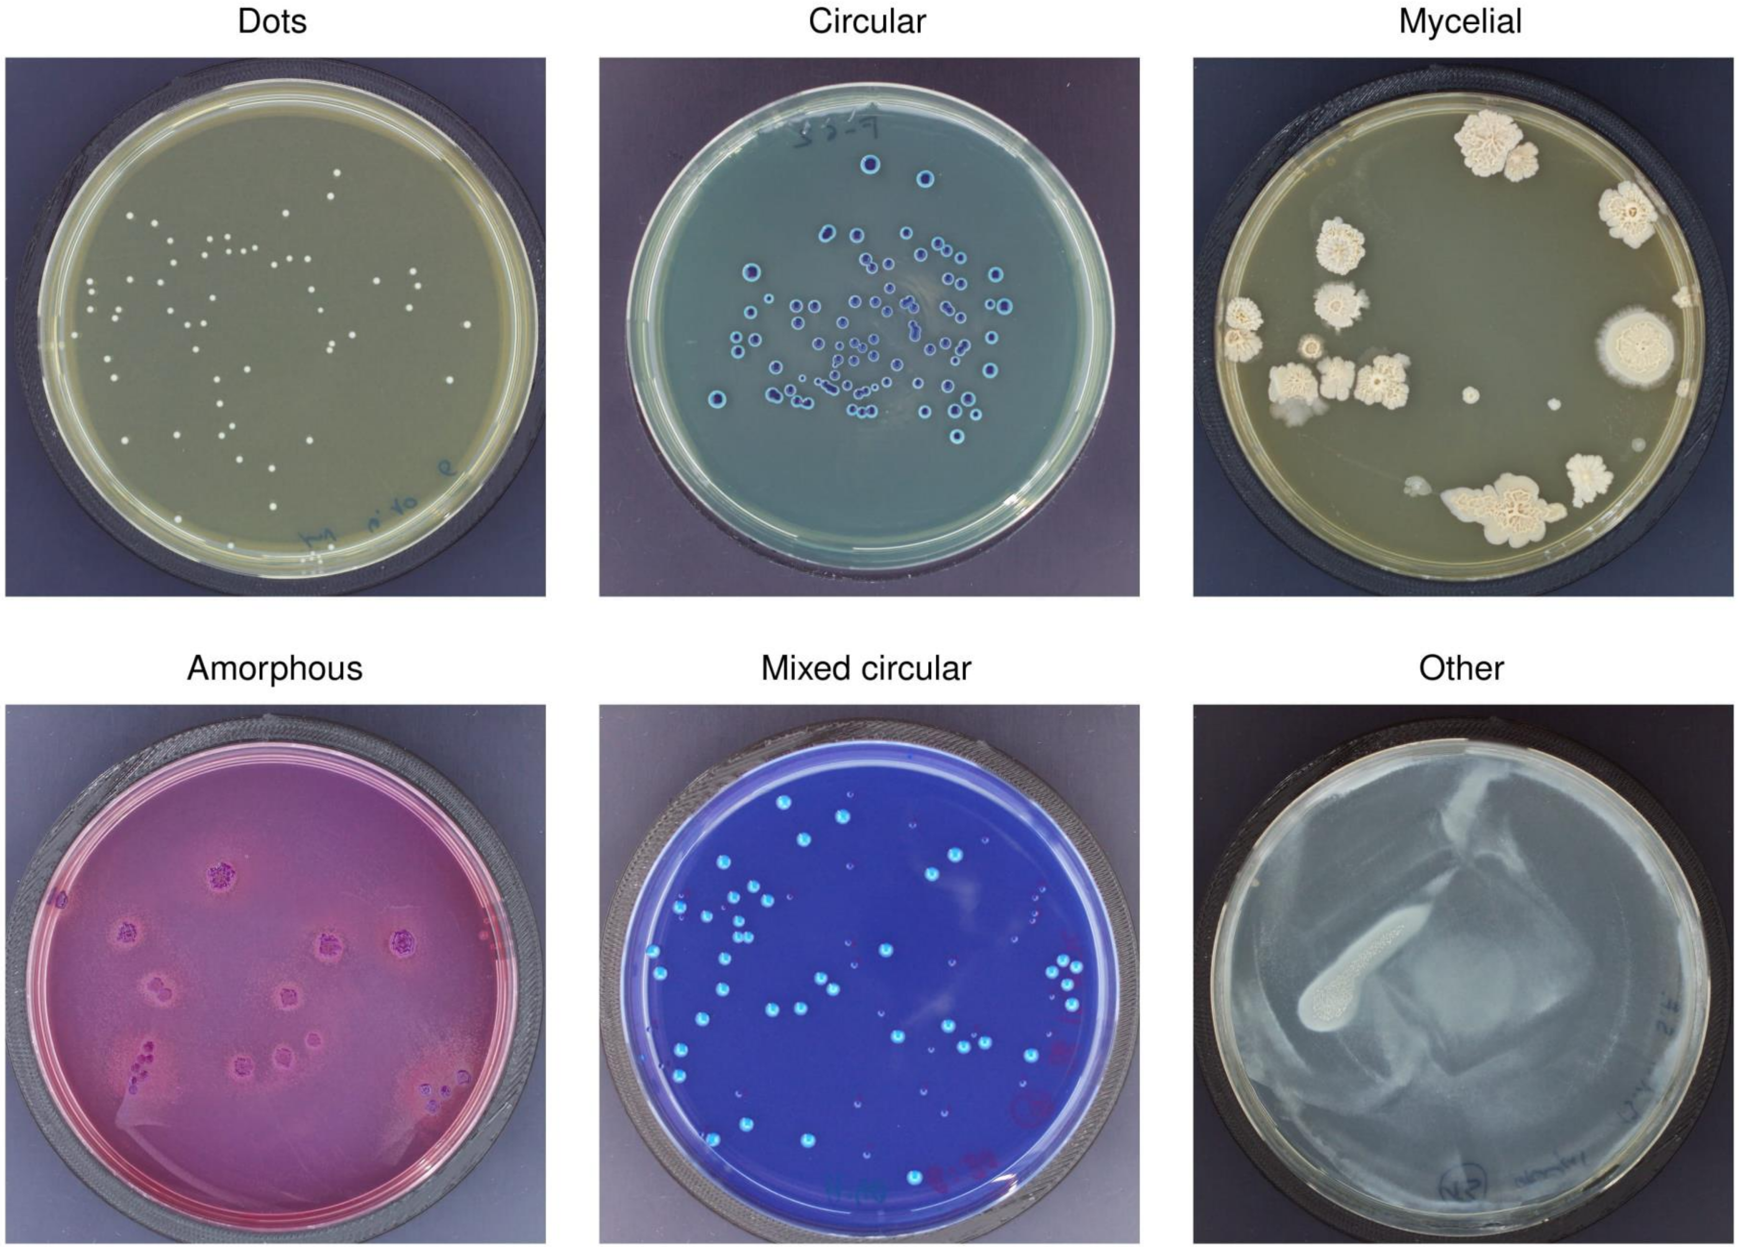

Dots

Circular

Mycelial

Amorphous

Mixed circular

Other

# Labeling

- Wissenschaftliche Mitarbeiterin markierte Kolonien mit iPad
- Kann nicht direkt für Computer Vision verwendet werden
- Muss in gelabelte Daten überführt werden

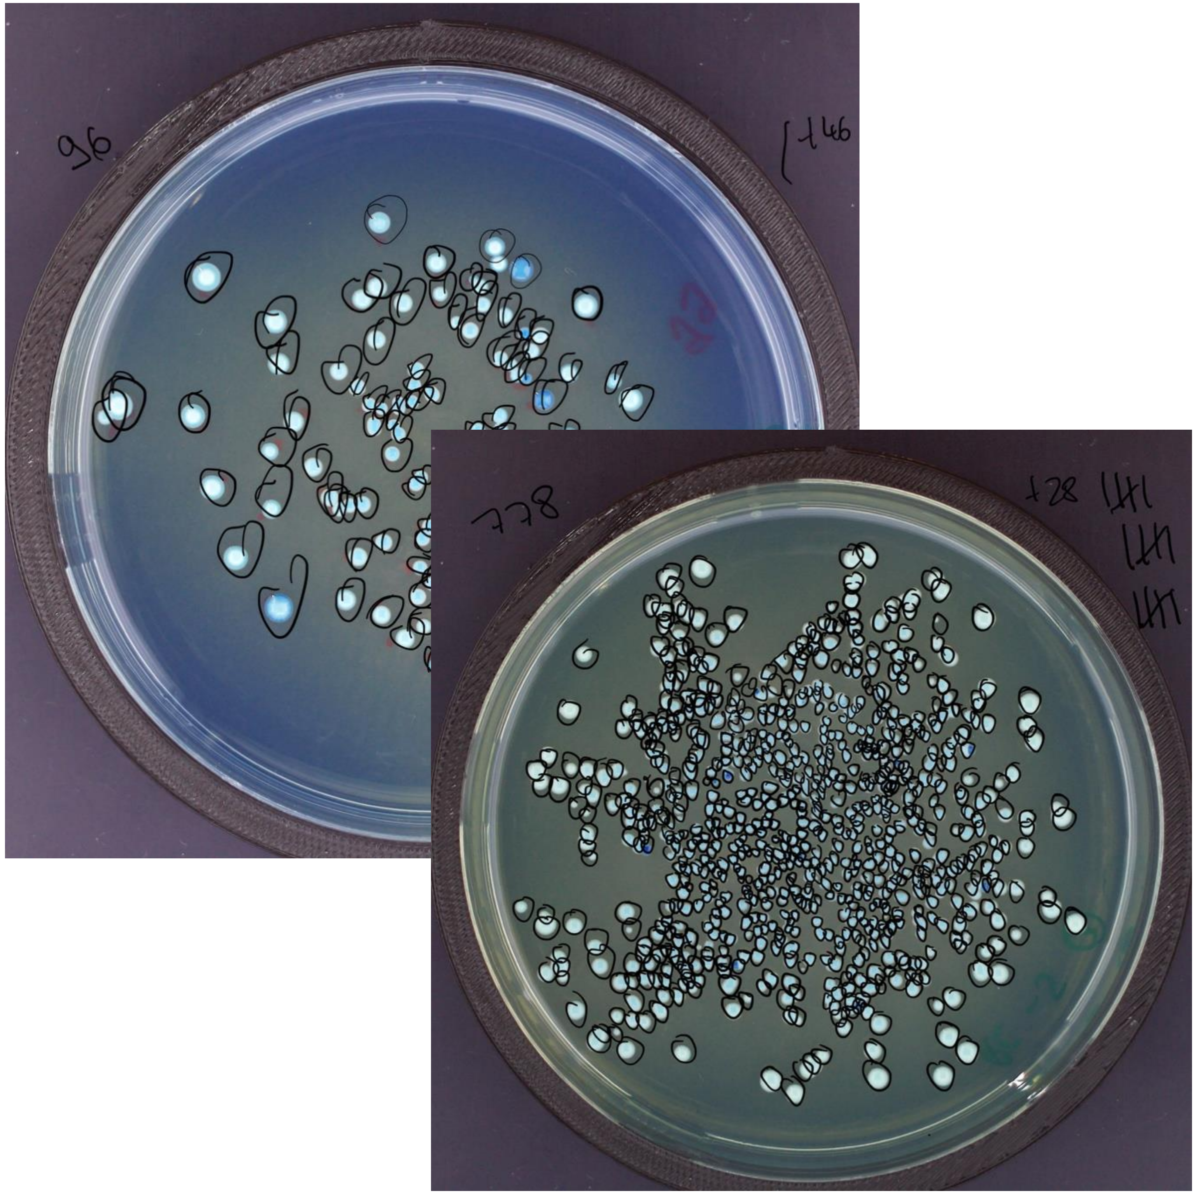

# Das Labeling-Programm

- Web-App gestützt von Segment Anything
- Jede Kolonie einmal anklicken
- So habe ich 200 iPad-annotierte Bilder in digital überführt
- Kann in Zukunft weiter genutzt werden

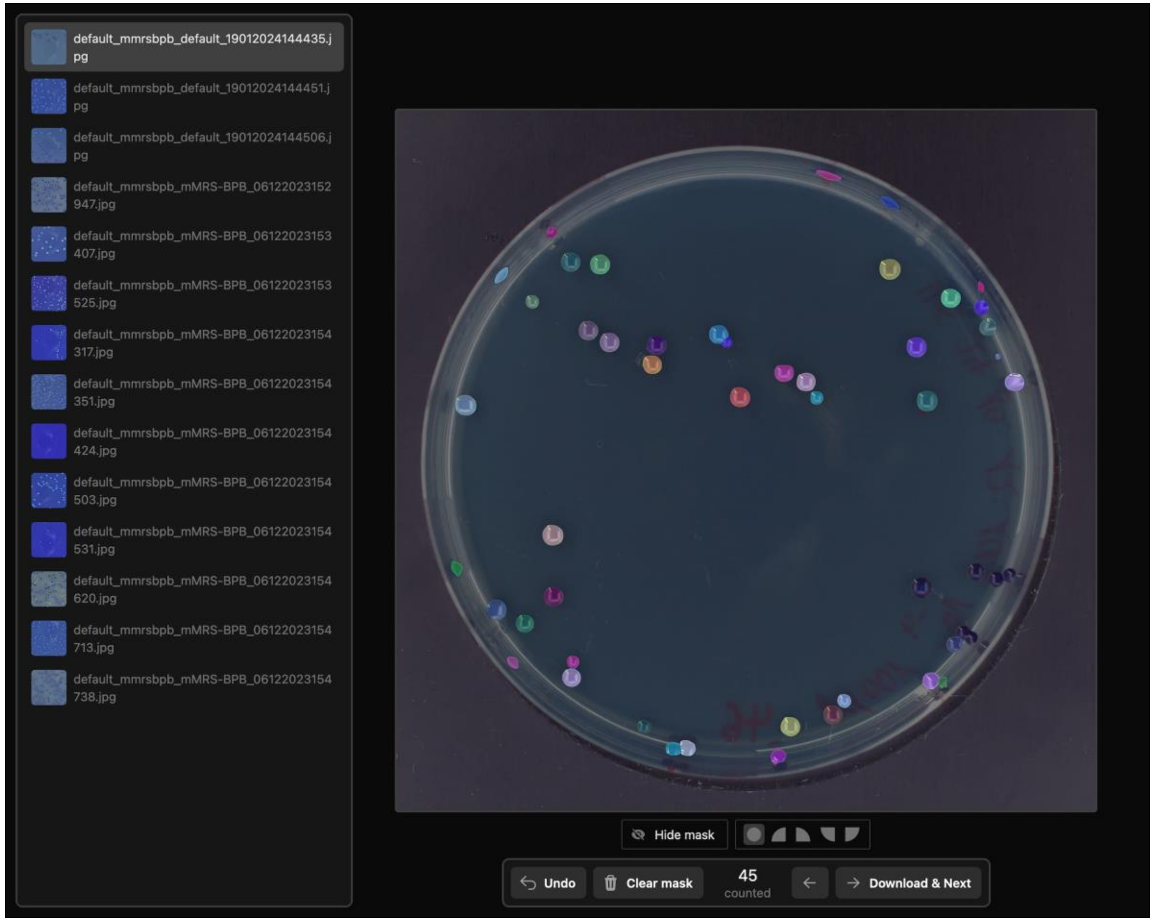
default_mmrsbpb_default_19012024144435.jpg
default_mmrsbpb_default_19012024144451.jpg
default_mmrsbpb_default_19012024144506.jpg
default_mmrsbpb_mMRS-BPB_06122023152947.jpg
default_mmrsbpb_mMRS-BPB_06122023153407.jpg
default_mmrsbpb_mMRS-BPB_06122023153525.jpg
default_mmrsbpb_mMRS-BPB_06122023154317.jpg
default_mmrsbpb_mMRS-BPB_06122023154351.jpg
default_mmrsbpb_mMRS-BPB_06122023154424.jpg
default_mmrsbpb_mMRS-BPB_06122023154503.jpg
default_mmrsbpb_mMRS-BPB_06122023154531.jpg
default_mmrsbpb_mMRS-BPB_06122023154620.jpg
default_mmrsbpb_mMRS-BPB_06122023154713.jpg
default_mmrsbpb_mMRS-BPB_06122023154738.jpg
Hide mask
Undo
Clear mask
45
counted
Download & Next

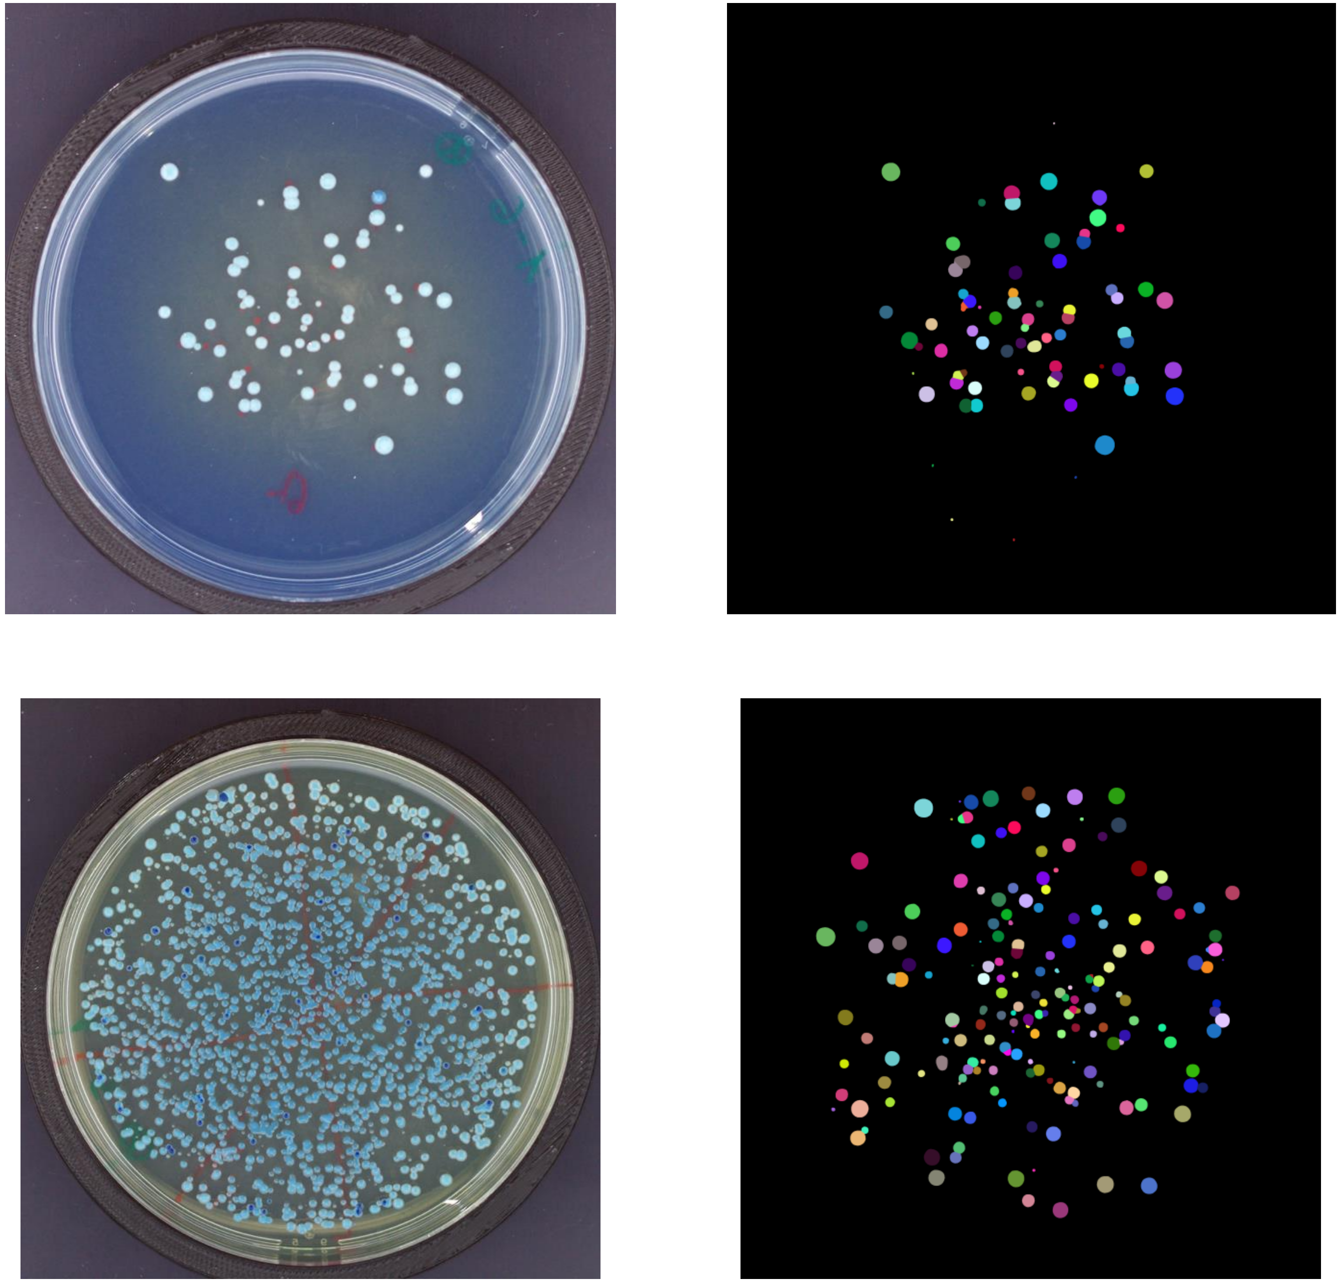

# Guter Startpunkt

- Sehr genaue Daten
- Vielfältig einsetzbar

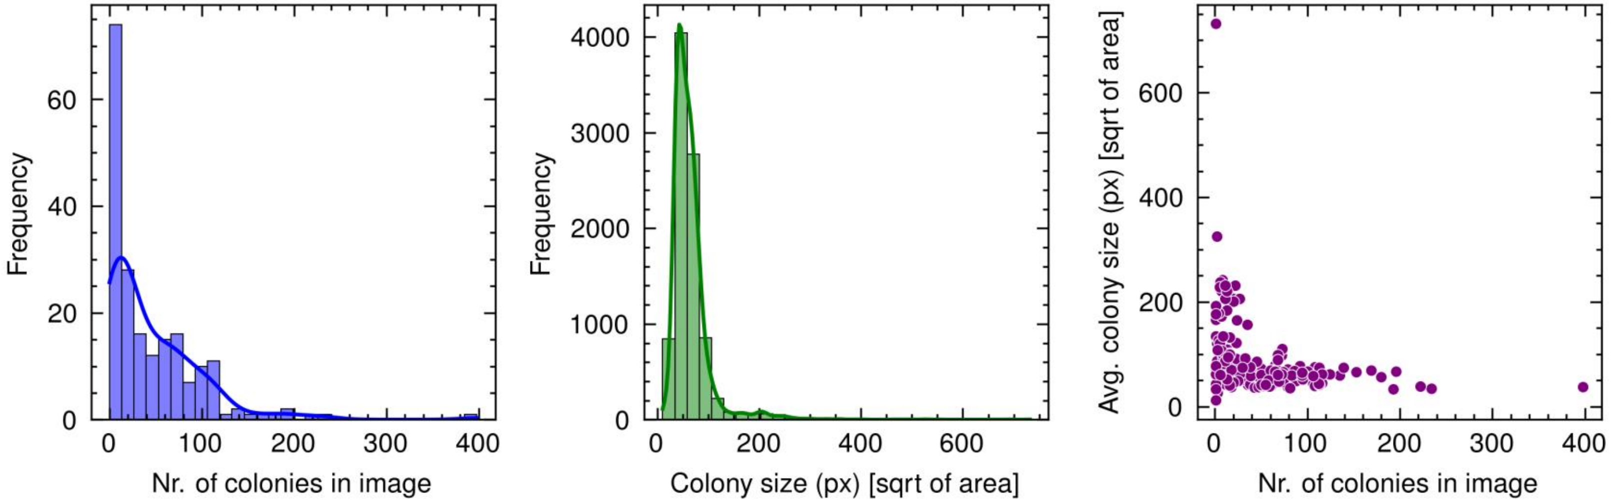
Frequency
60
40
20
0
0
100
200
300
400
Nr. of colonies in image
Frequency
4000
3000
2000
1000
0
0
200
400
600
Colony size (px) [sqrt of area]
Avg. colony size (px) [sqrt of area]
600
400
200
0
0
100
200
300
400
Nr. of colonies in image

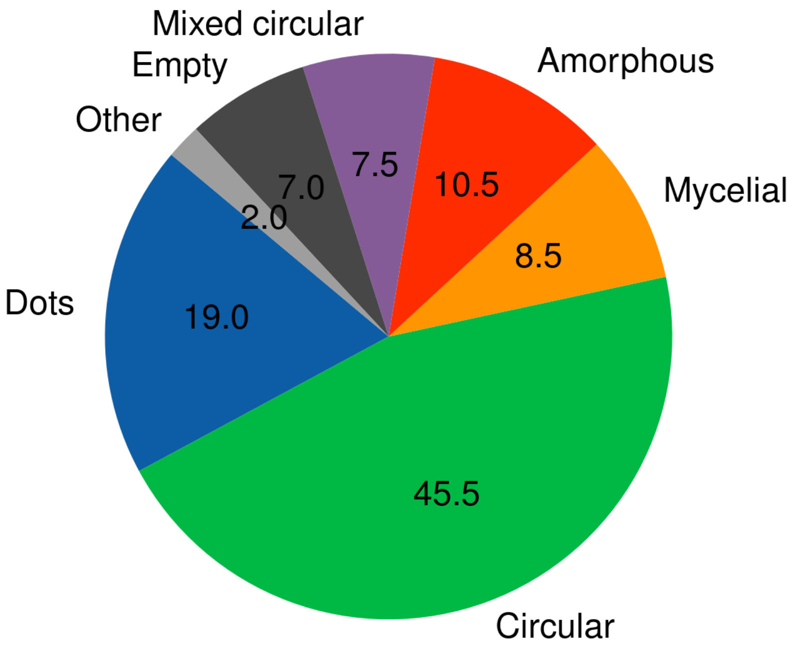
Mixed circular
Empty
Other
Amorphous
Mycelial
Dots
Circular
7.5
7.0
2.0
10.5
8.5
19.0
45.5

# Ansätze

# Traditioneller CV-Ansatz

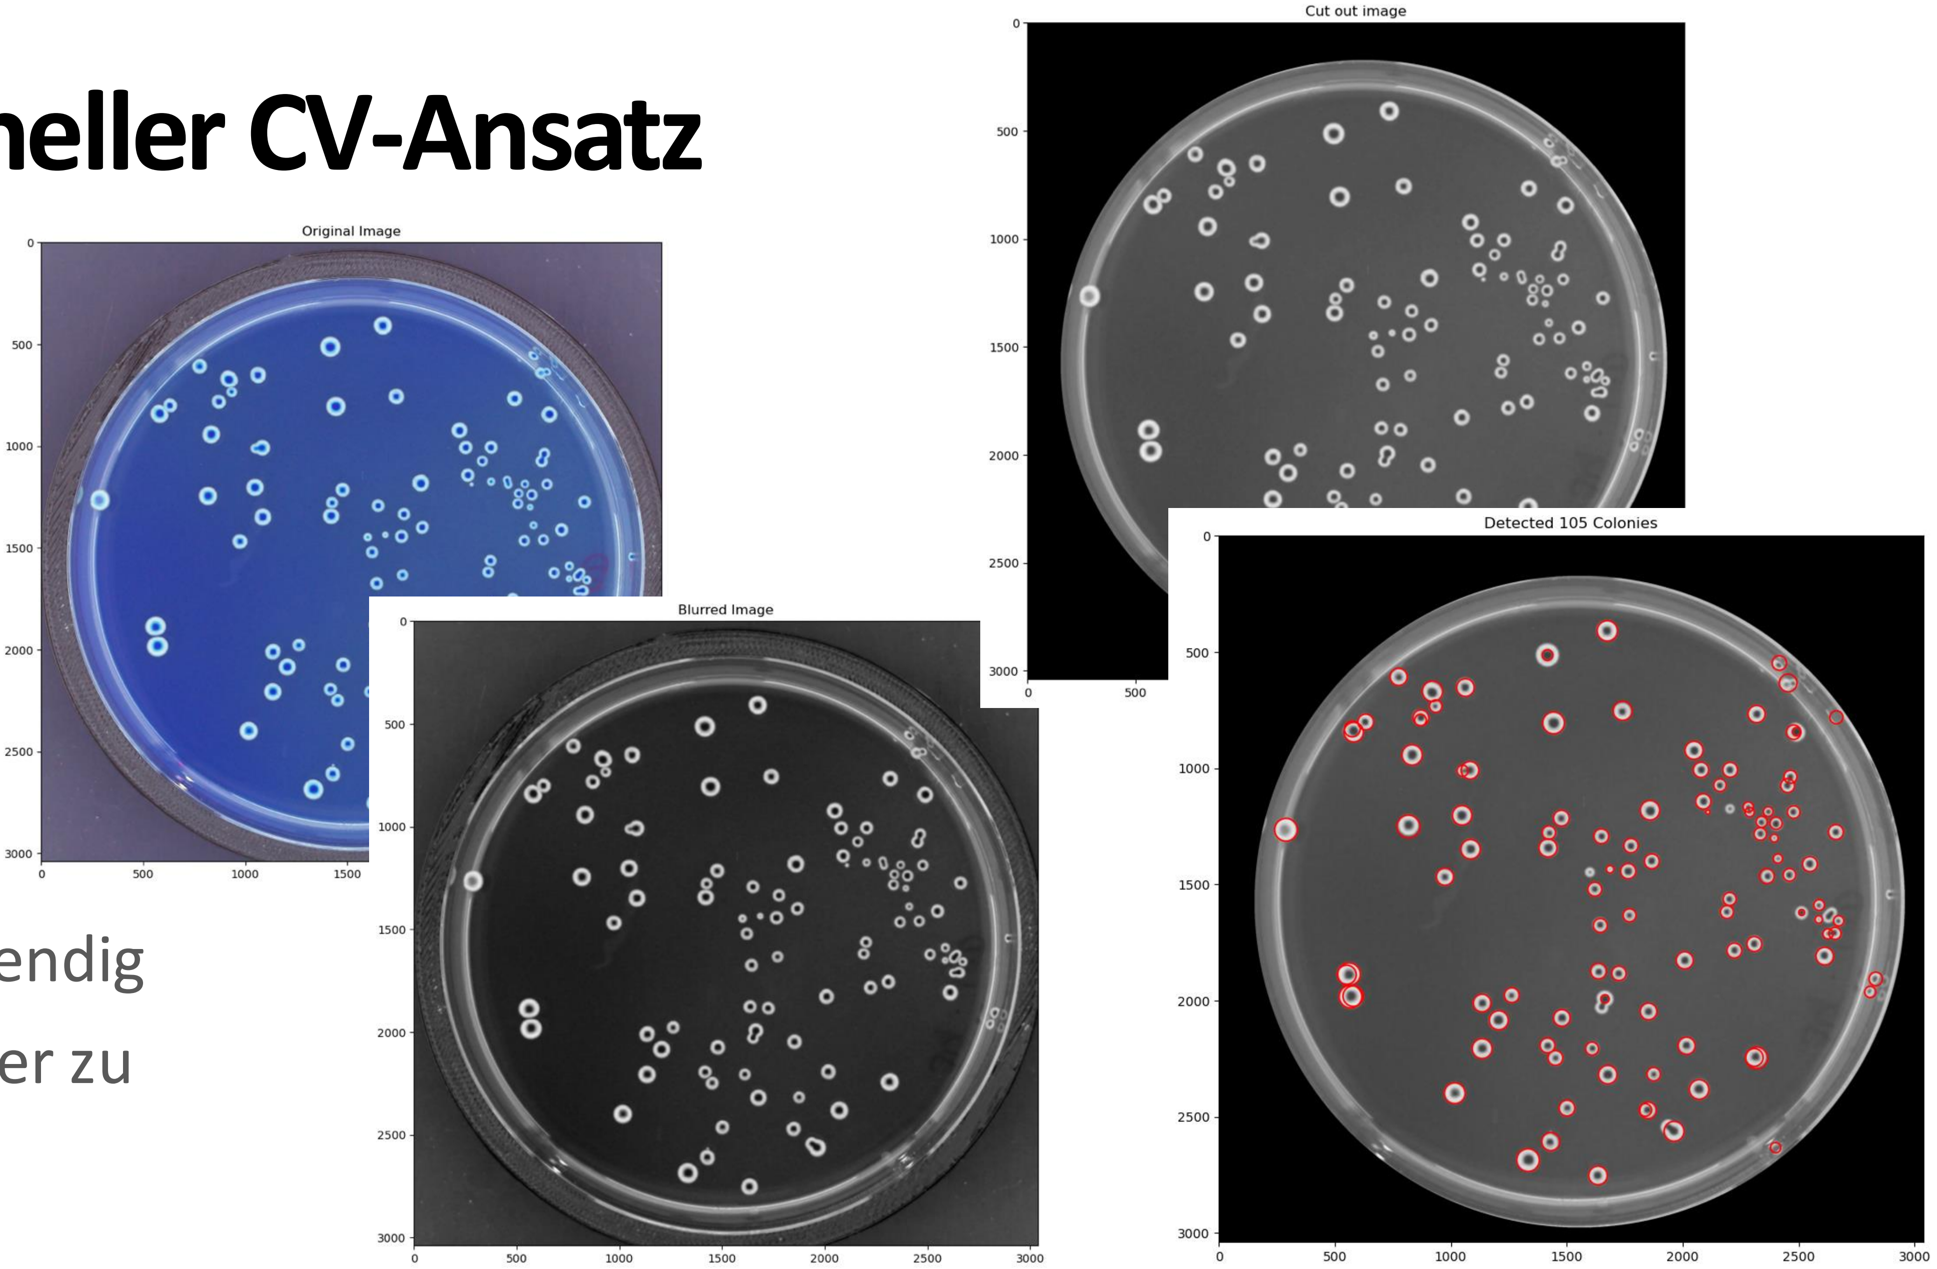

- Kein ML notwendig
- Viele Parameter zu tunen
- Unflexibel

# Hybrid Ansatz

- Ferrari et al.
- Segmentierung mit Thresholding/Watershed
- Klassifierung von Regionen nach Anzahl der Kolonien

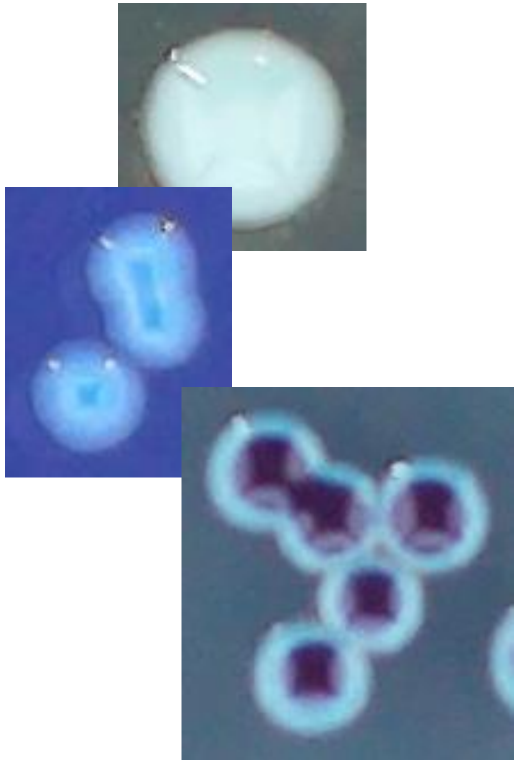

# Hybrid Ansatz

- Thresholding schwierig
  - Unterschiedliche Hintergründe
  - Verschiedene Kontraste
- Klassifizierung scheint gut möglich
  - Ferrari et al. erreichen 92% Accuracy beim Zählen der Kolonien in Bildausschnitten

# End-to-End Ansatz

- Vollständige Bilder als Input für Deep Learning Modell
- Ausgabe von Masken/Bounding Boxes

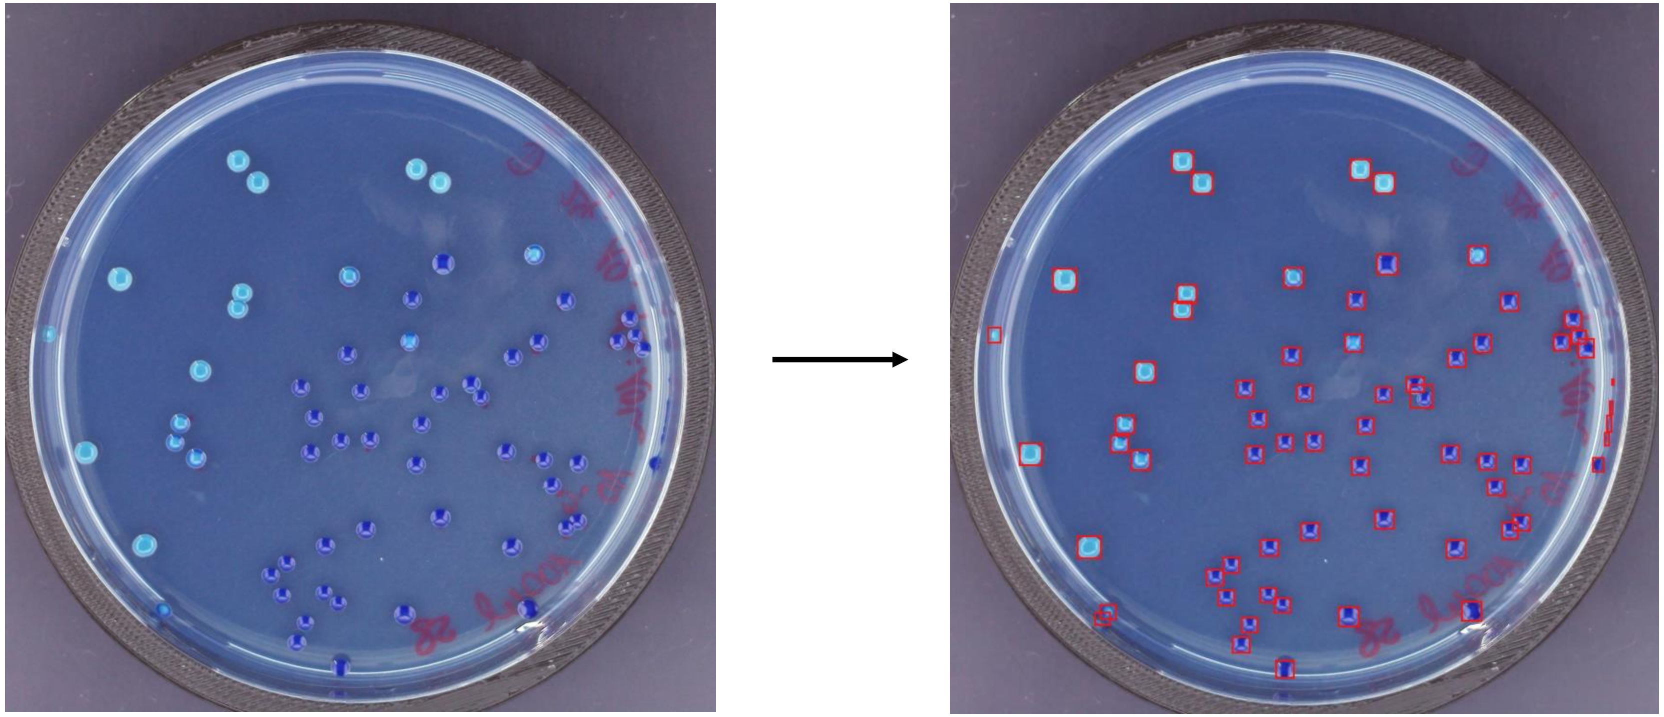

# End-to-End Ansatz

- Sehr flexibel
- Passt sich “automatisch” Trainingsdaten an (Hintergründe, Formen der Kolonien, etc.
- Compute-intensiver
- Viel über Experimentation

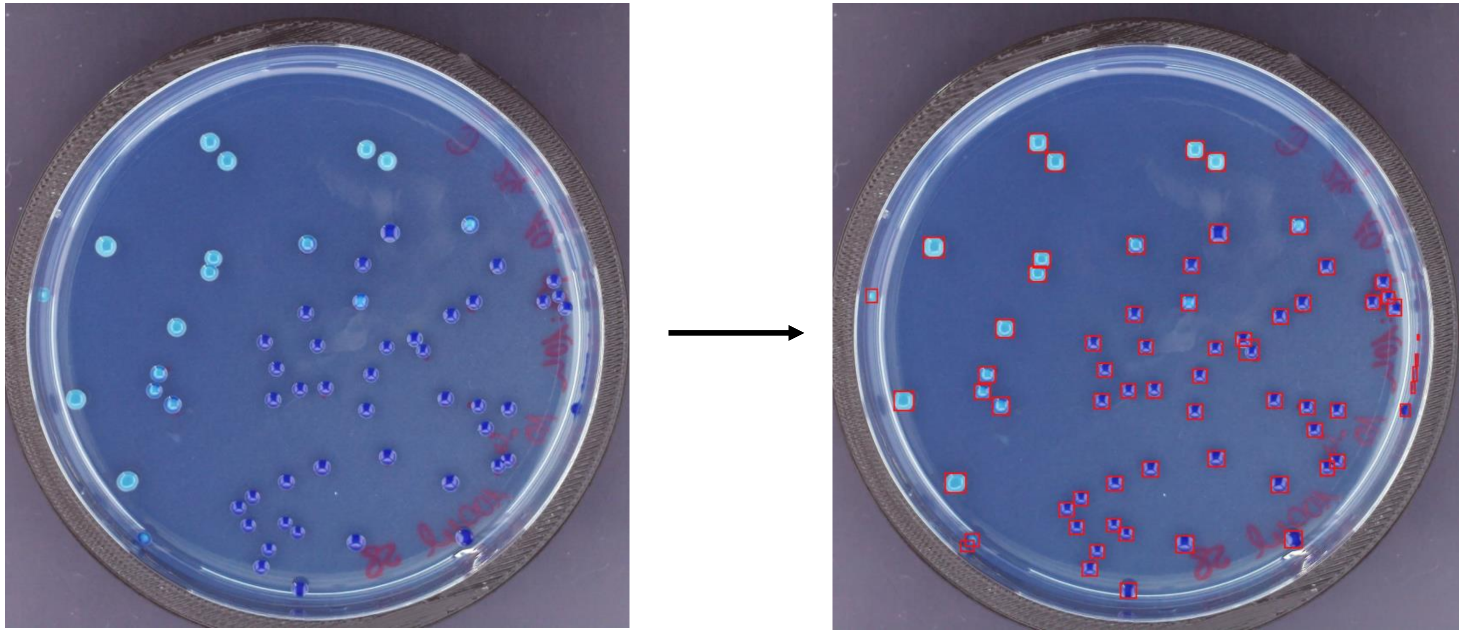

# Umsetzung

# Modell heraussuchen

- PyTorch gefragt
- Majchrowska et al. zeigt, dass Modellarchitektur geringen Einfluss auf Performance hat
- Faster / Mask R-CNN sind bekannt, haben PyTorch Implementation und viele Online-Ressourcen

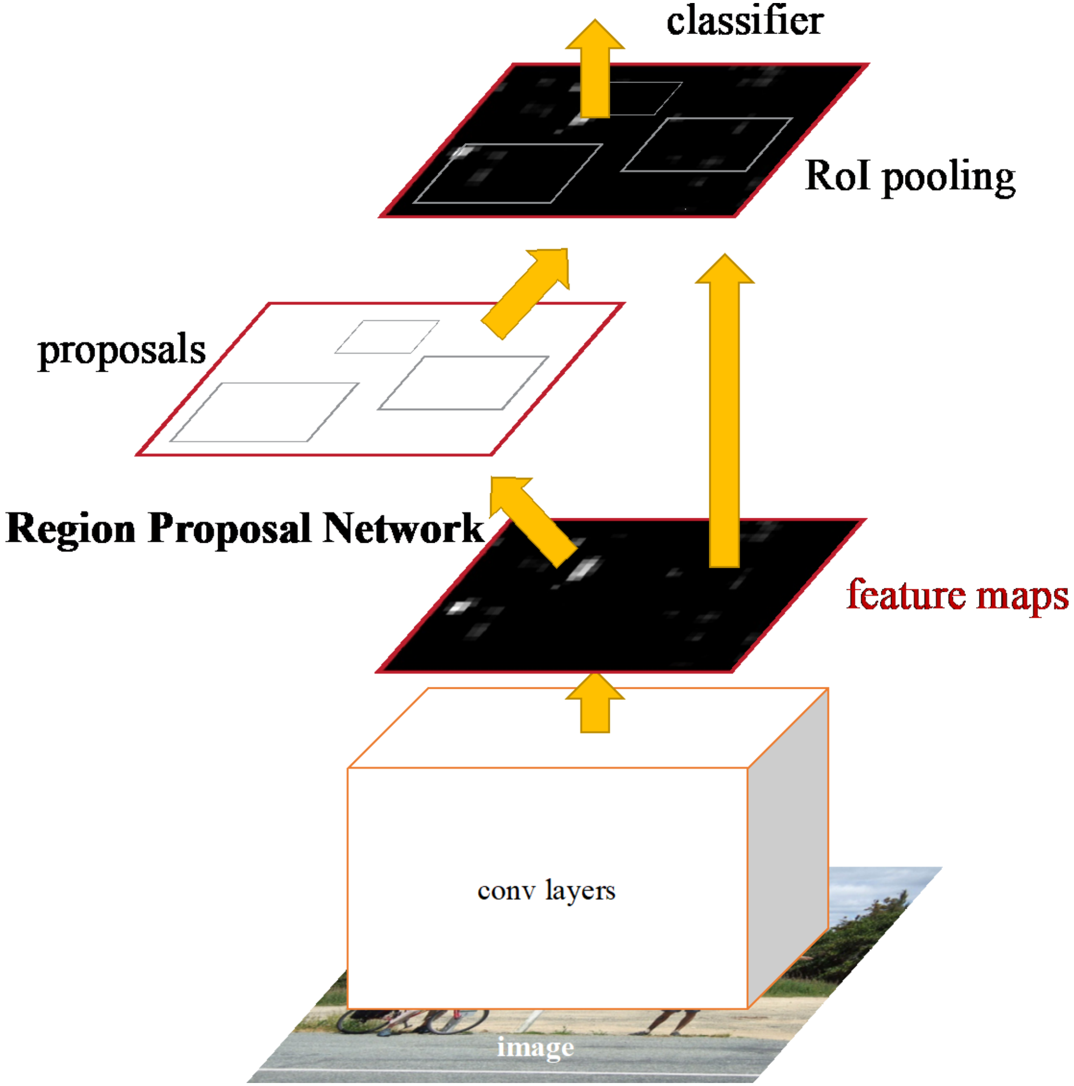

classifier

RoI pooling

proposals

**Region Proposal Network**

feature maps

conv layers

image

# Implementation

- Modell an sich von PyTorch importiert (keine Layer müssen definiert werden)
- Pre-Trained Weights von COCO können ebenfalls importiert werden
- Implementation des Datasets / Transforms / Trainings über mehrere .py-Dateien verteilt

# Experimente

# Bildtransformationen

- Rotation (90, 180, 270 Grad)

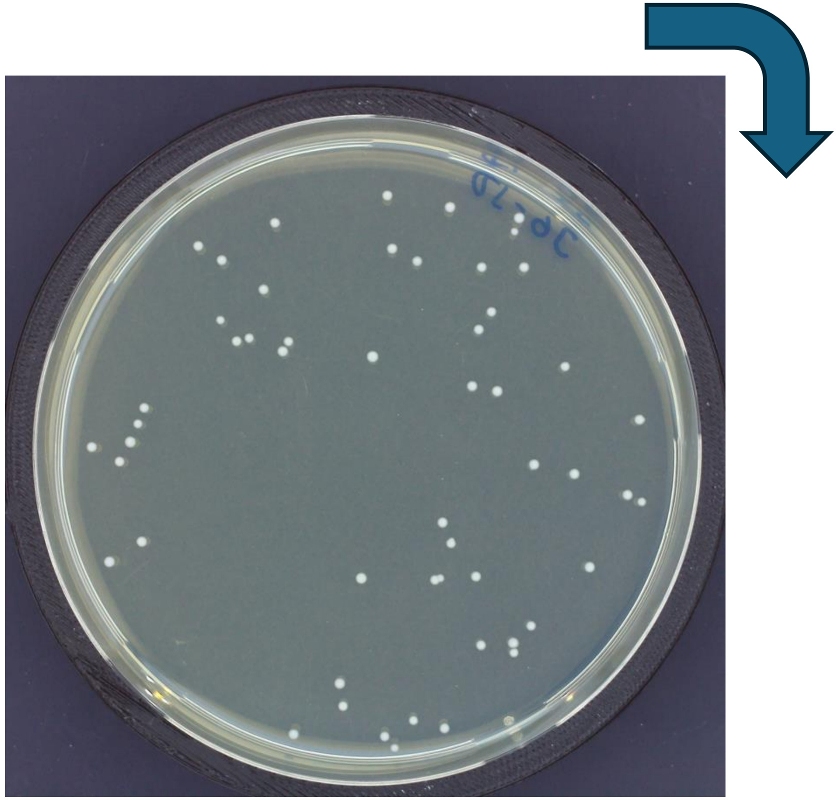

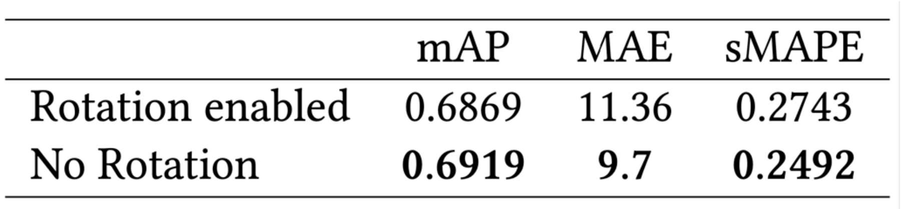

| | mAP | MAE | sMAPE |
|---|---|---|---|
| Rotation enabled | 0.6869 | 11.36 | 0.2743 |
| No Rotation | **0.6919** | **9.7** | **0.2492** |

# Abdecken + Inpainting

- Kolonien im Bild verdecken um neue Bilder zu erschaffen
- Ähnlich wie Zhang et al.

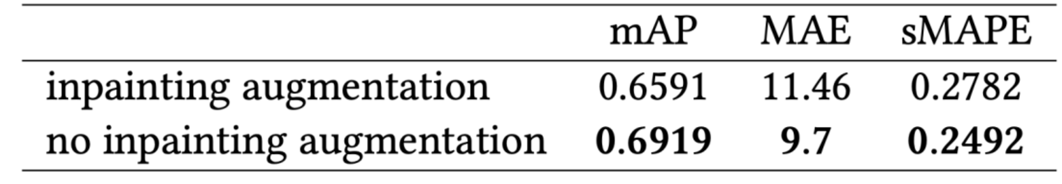

| | mAP | MAE | sMAPE |
|---|---|---|---|
| inpainting augmentation | 0.6591 | 11.46 | 0.2782 |
| no inpainting augmentation | **0.6919** | **9.7** | **0.2492** |

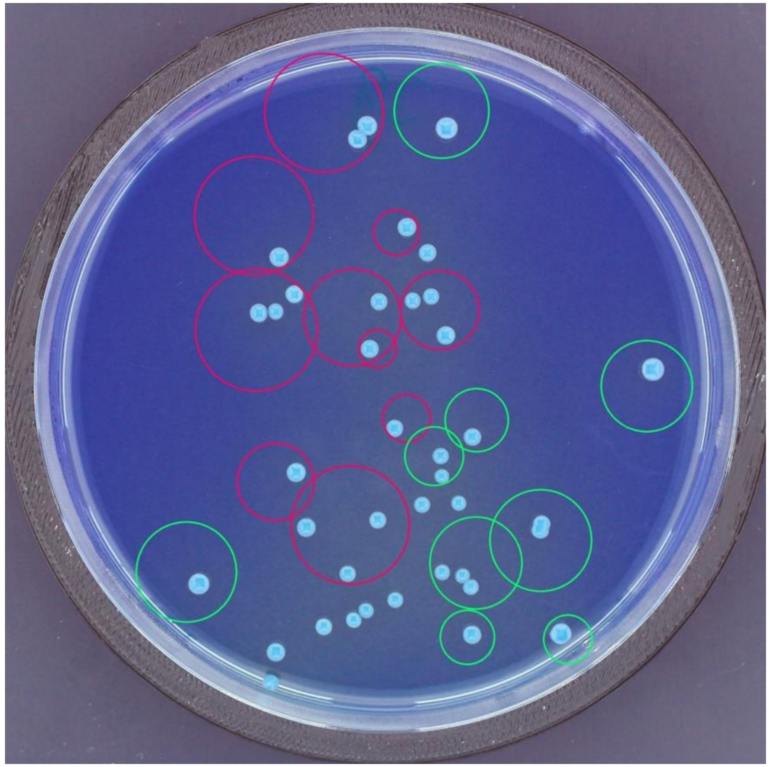

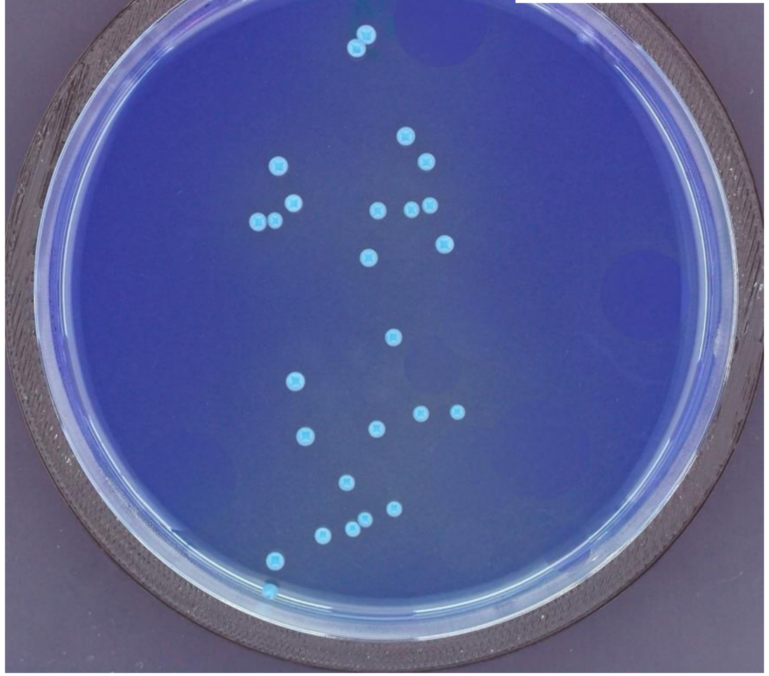

# Pretraining mit anderen Datasets

- Modell vor dem Trainieren mit dem hauseigenen Datensatz “vorwärmen”
- AGAR Dataset von Majchrowska et al.

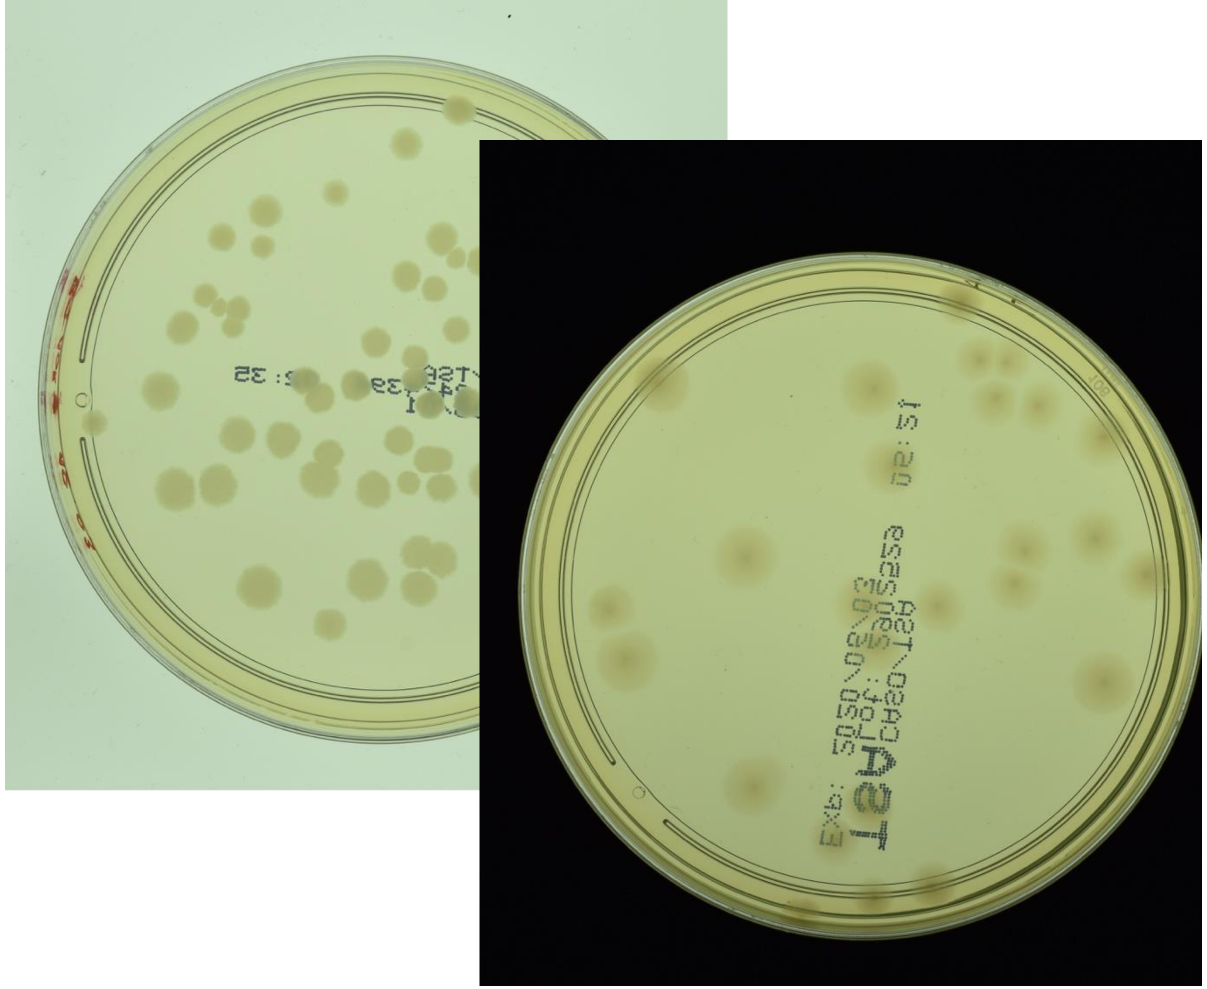

# Pretraining mit anderen Datasets

- Modell vor dem Trainieren mit dem hauseigenen Datensatz “vorwärmen”
- COCO Dataset von Microsoft

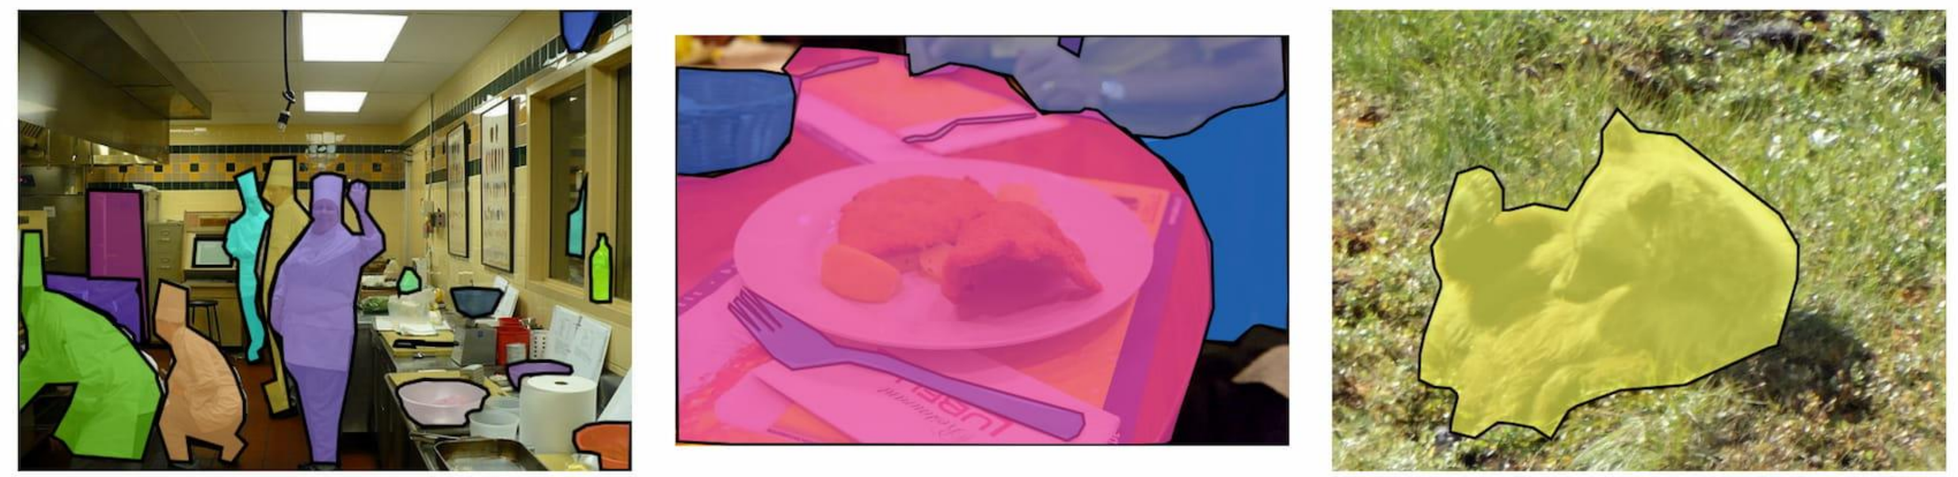

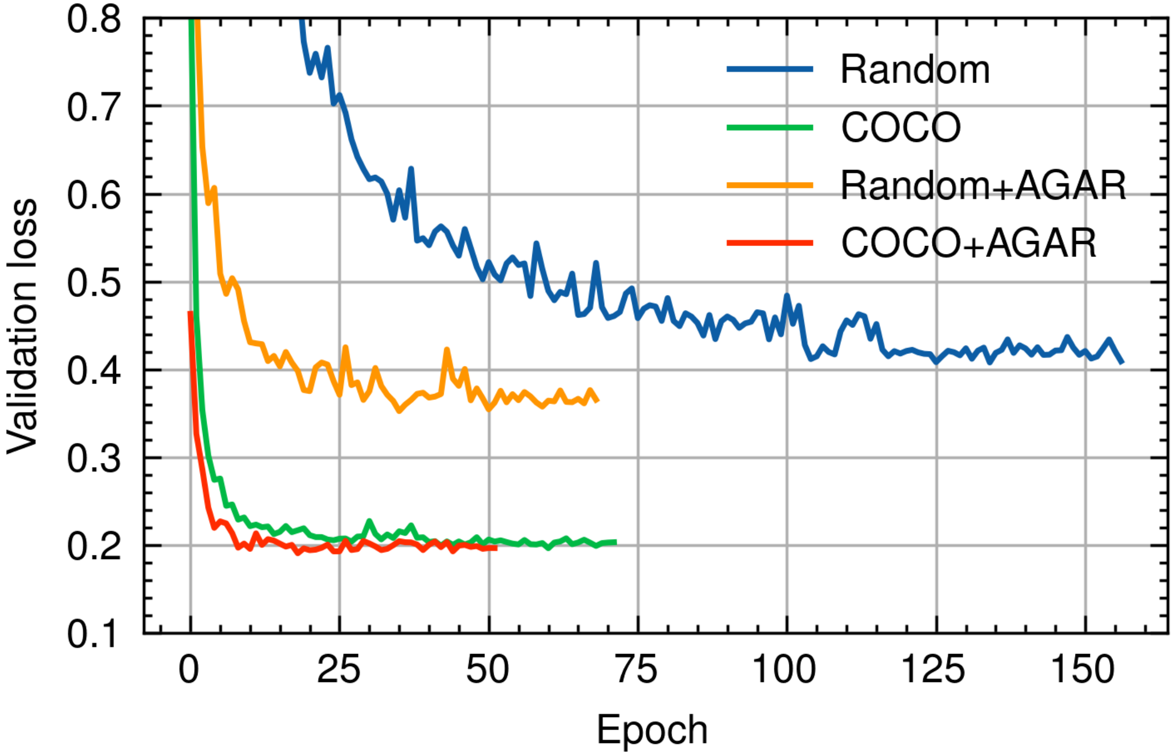

| | Epochs | mAP | MAE | sMAPE |
|---|---|---|---|---|
| Random | 156 | 0.6919 | 9.7 | 0.2492 |
| COCO | 71 | 0.7607 | 6.92 | 0.1842 |
| Random+AGAR | 68 | 0.7065 | 8 | 0.1608 |
| COCO+AGAR | **51** | **0.7908** | **4.64** | **0.1356** |

# Und viele mehr…

- Optimizer (**SGD**, Adam, AdamW)
- Batch size, Gradient Clipping
- Bildauflösungen (800 x 800px)
- …

# Ergebnisse

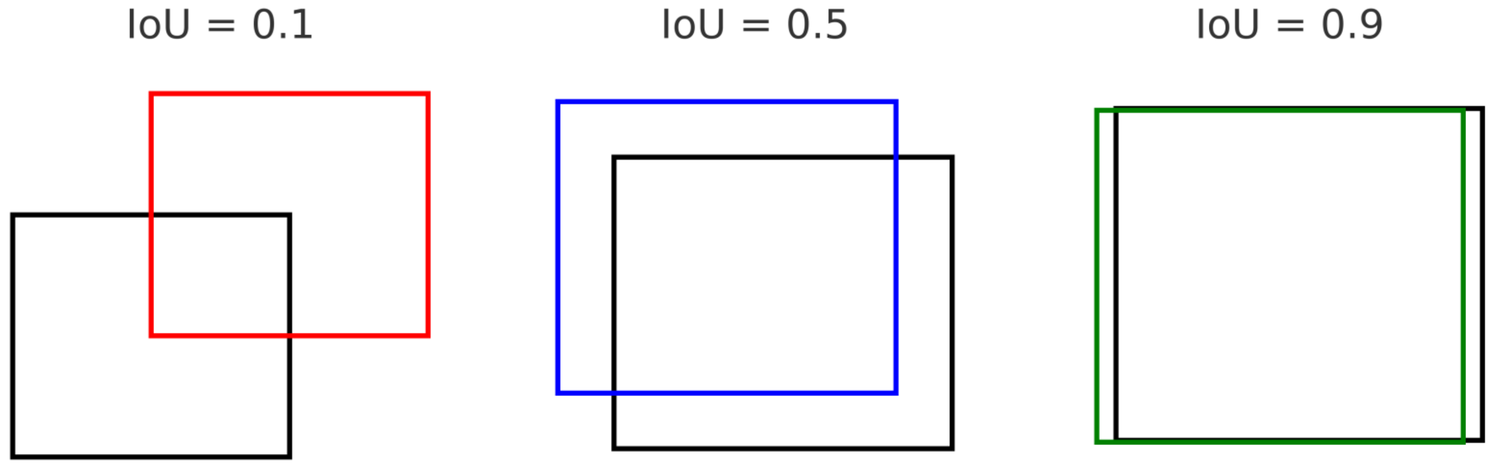
IoU = 0.1
IoU = 0.5
IoU = 0.9

# Zahlen

- 50 Testbilder
- 92,9% Präzision beim Erkennen von Kolonien
- 87,3% Recall
- 6,26 Kolonien daneben durchschnittlich

- Kleines Datenset, Zahlen nicht 100% zuverlässig

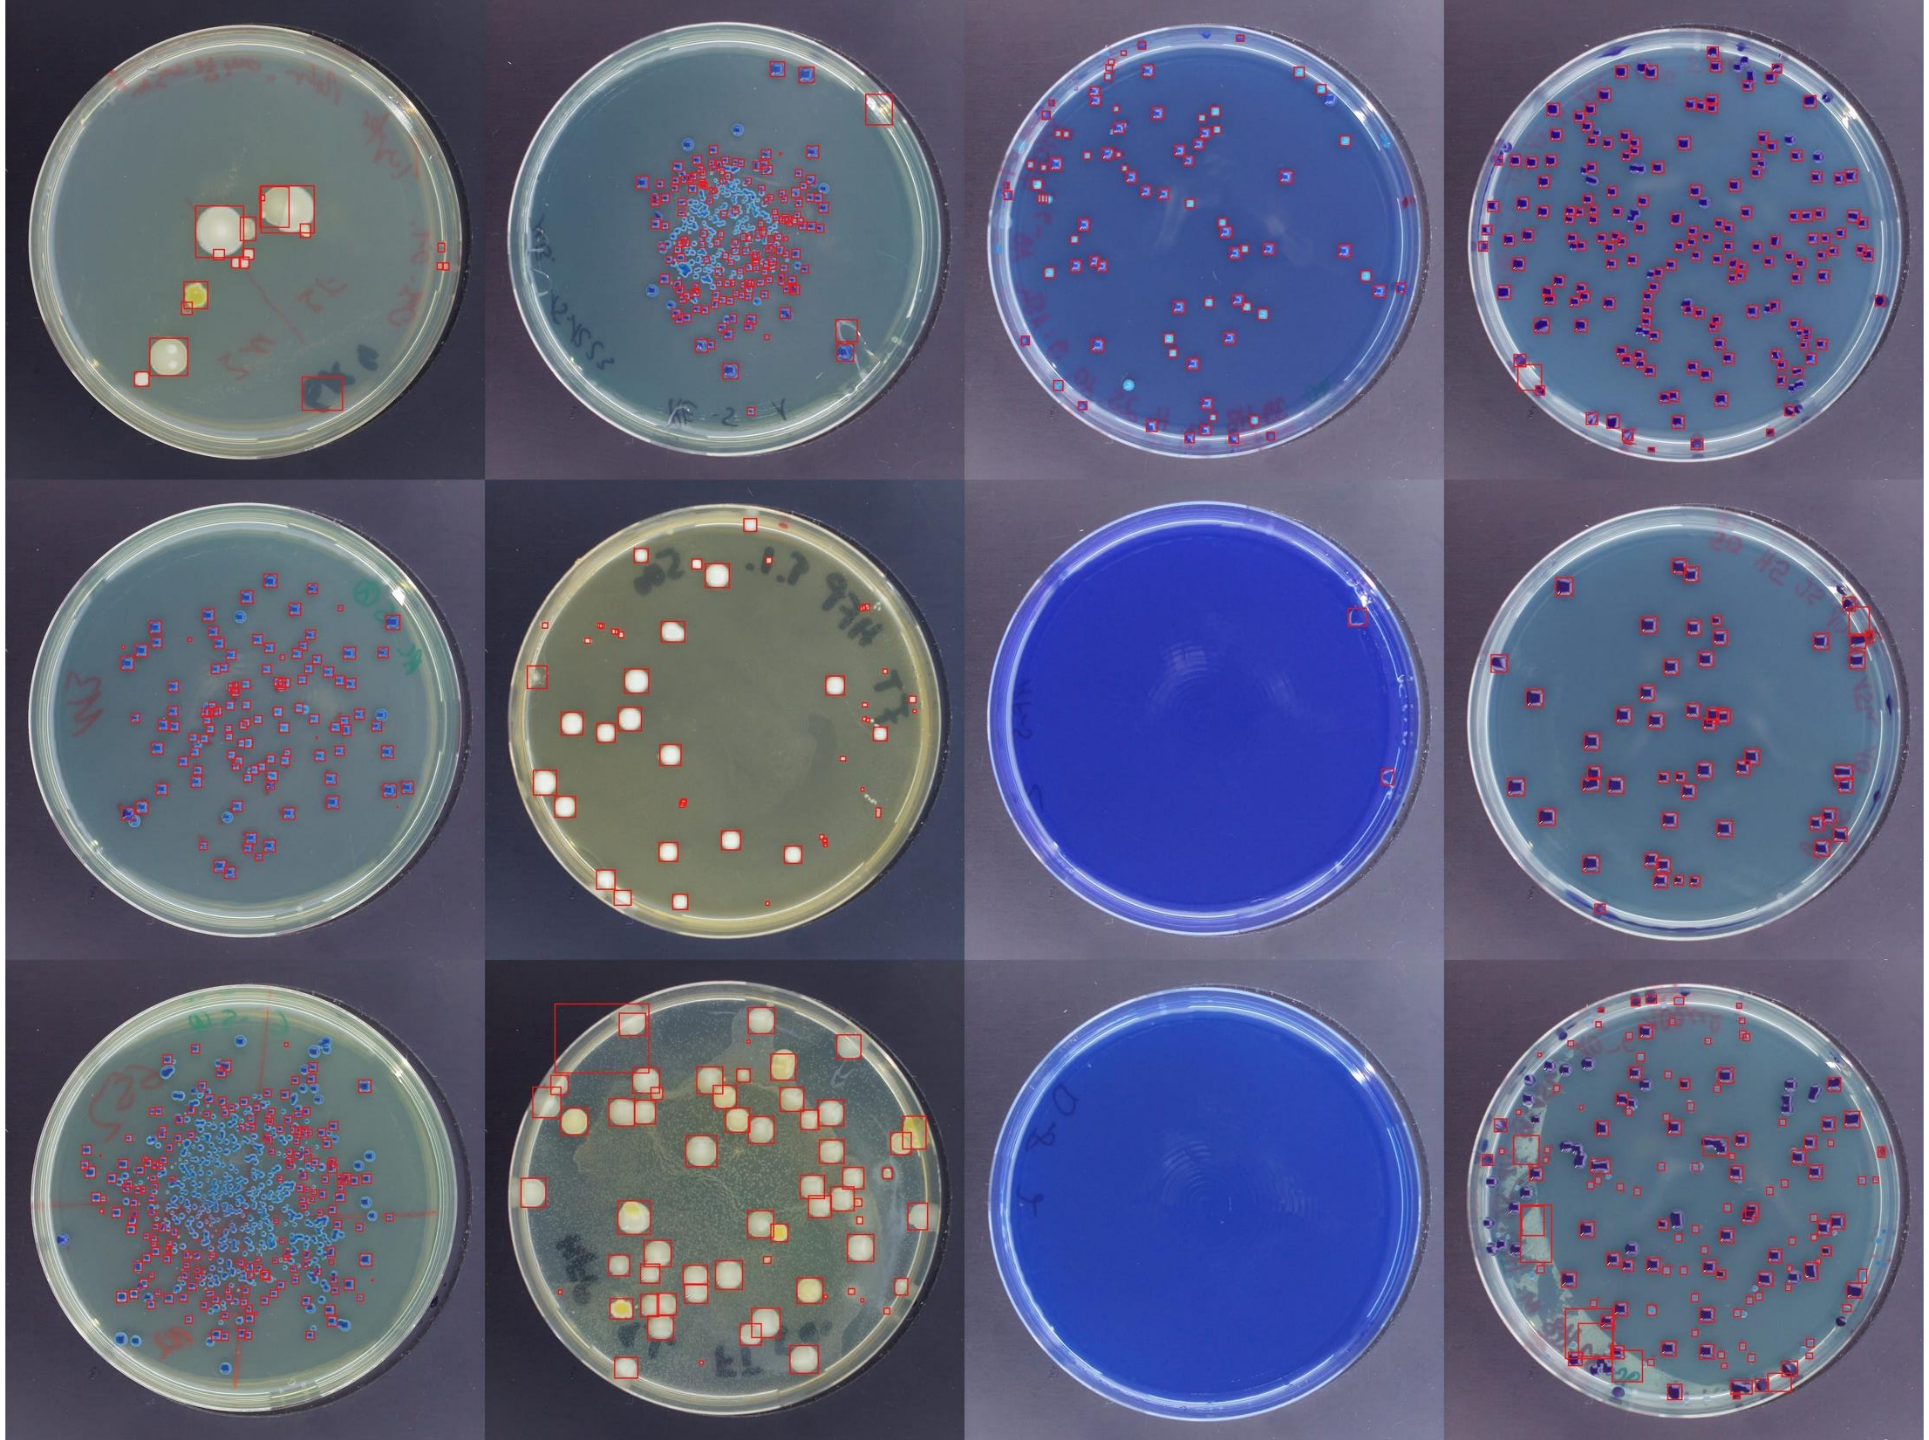

# Nutzung des Modells

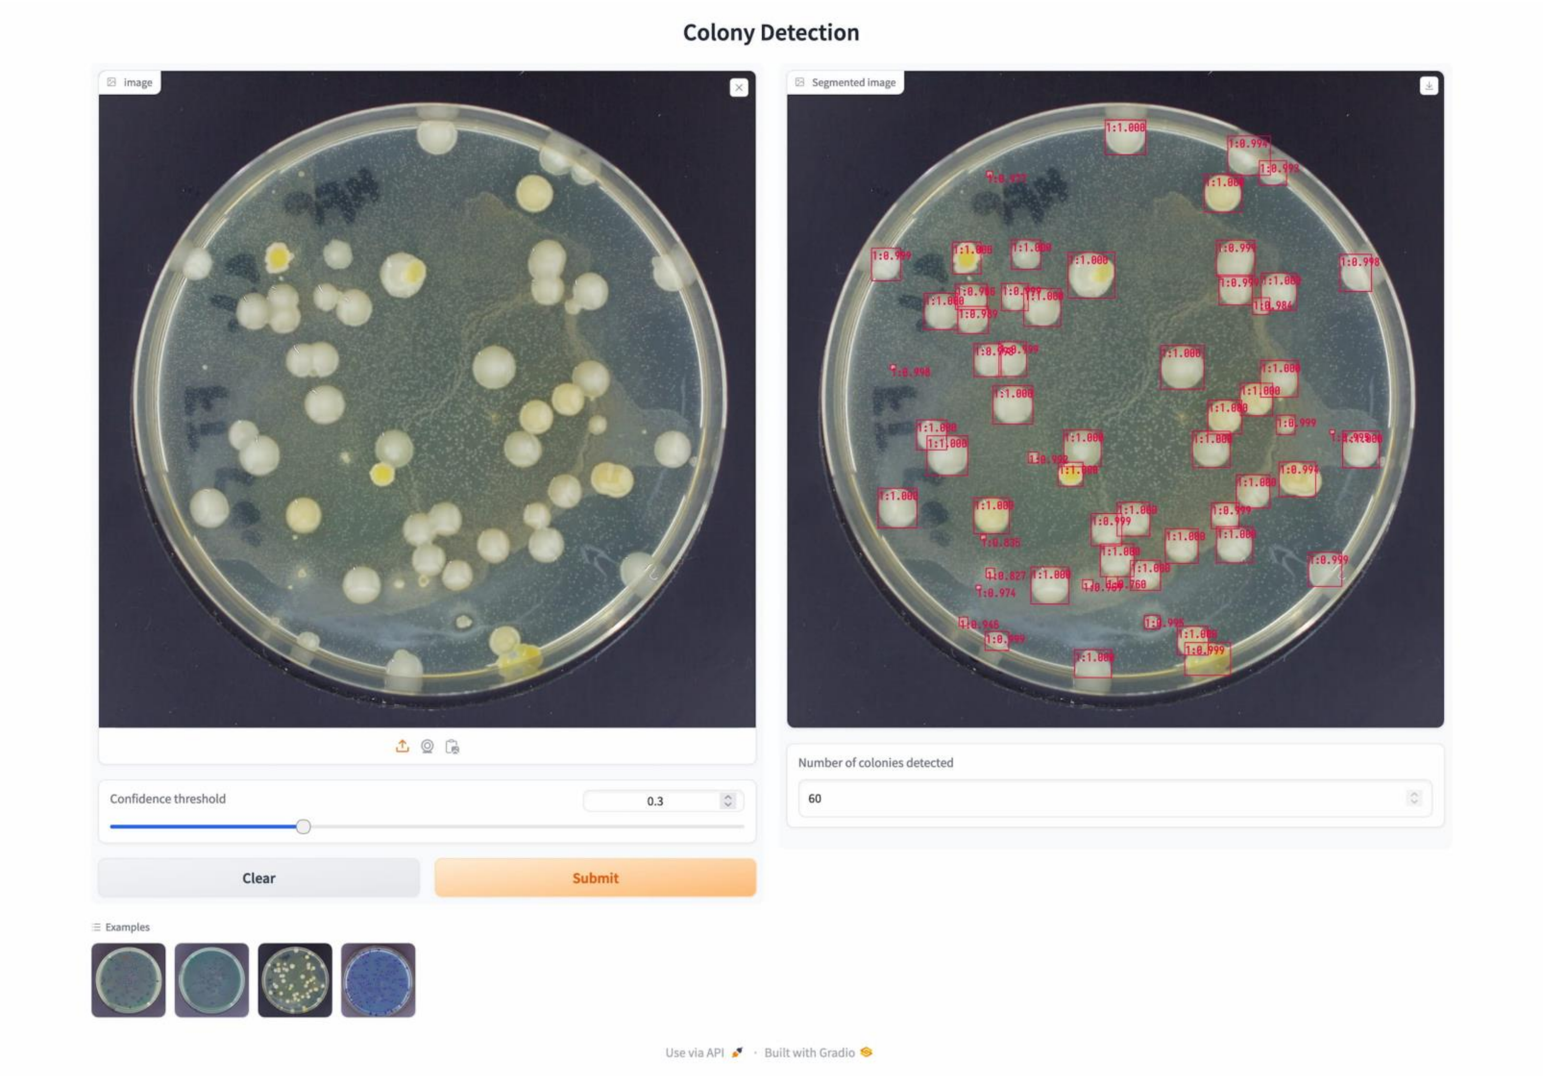

Colony Detection

Confidence threshold: 0.3

Number of colonies detected: 60

image
Segmented image
Clear
Submit
Examples
Use via API
Built with Gradio

# Ausblick

- Modell jetzt verwenden als Helfer
- Labeling Tool & Anwendung zur Interferenz verknüpfen um Kreis zwischen Dataset & Anwenden zu schließen
- Architekturen testen
- Kolonien klassifizieren
- Smartphone-Bilder zum Trainieren verwenden

# Automating Bacterial Colony Segmentation with Deep Learning

Bachelor’s Thesis by Leonhard Driesch,
University of Münster – Computer Science Department

# Quellen

- https://www.kisker-biotech.com/product/0D-15-03
- Restliche Quellen: siehe Bachelorarbeit